

Análise de sentimentos em críticas de filmes

AGEMC aplicado ao IMDb Dataset, comparando TF-IDF, modelos ensemble e embeddings semânticos.

Machine Learning

Estrutura do projeto

A

Ask

Definir se o texto de uma review permite prever o sentimento.

G

Get

Obter o IMDb Dataset com reviews e rótulos positivos/negativos.

E

Explore

Limpar textos, verificar classes, separar treino/teste e vetorizar.

M

Model

Treinar Regressão Logística baseline, modelos ensemble e Embeddings + Regressão Logística.

C

Communicate

Comparar métricas, interpretar erros e responder ao **Ask**.

A

Pergunta principal

Levando em consideração o texto de uma crítica de filme, conseguimos prever automaticamente se ela expressa sentimento positivo ou negativo?

Tipo de problema

- Classificação binária de texto
- Entrada: texto da crítica
- Saída: sentimento positivo ou negativo

Objetivo analítico

- Testar se o texto contém informação suficiente
- Comparar representações e modelos
- Comunicar qual abordagem foi mais eficaz

G

Dados utilizados

50k

REVIEWS

Dataset público do IMDb,
disponibilizado no Kaggle.

2

CLASSES

Sentimentos positivos e negativos
usados como rótulos supervisionados.

80/20

SPLIT

Treino e teste com estratificação para
manter a proporção das classes.

O notebook imprime o total real carregado, pois o arquivo pode ser CSV, Parquet ou ter linhas malformadas ignoradas.

E

Preparação dos dados

Limpeza textual

- Remoção de tags HTML.
- Remoção de caracteres especiais e números.
- Conversão para letras minúsculas.
- Remoção de espaços extras.

Cuidados de avaliação

- Divisão estratificada em treino e teste.
- TF-IDF ajustado apenas no treino.
- Teste usado somente para comparação final.
- Sem undersampling, pois a base já é equilibrada.

Representações textuais

TF-IDF

- Técnica que representa textos pela importância das palavras
- Transforma palavras em pesos numéricos
- Usa palavras isoladas e pares de palavras
- Destaca termos úteis para diferenciar sentimentos

Importância

Embeddings

- Representação que transforma textos em vetores de significado
- Cada crítica vira um vetor numérico que resume seu conteúdo
- Usa um modelo pré-treinado (`all-MiniLM-L6-v2`) para captar relações semânticas

Semântica

X

M

Modelos avaliados

Baseline

- Regressão Logística
- Modelo linear de classificação aplicado a textos representados por TF-IDF
- Solução simples, rápida e forte para texto esparso

Ensembles

- Combinam múltiplas decisões para formar uma previsão final
- Buscam capturar padrões mais complexos nos dados
- XGBoost
- LightGBM
- Random Forest
- Stacking

Semântico

- Embeddings + Regressão Logística
- Representação semântica em vez de TF-IDF

Fluxo implementado no notebook

1

Dados

Carrega o IMDb Dataset e trata possíveis linhas malformadas

2

Texto

Limpa as reviews e transforma os rótulos em valores numéricos

3

Vetores

Cria representações com TF-IDF e embeddings

4

Modelos

Treina os modelos e calcula as métricas de avaliação

5

Resultados

Gera tabelas, gráficos, matriz de confusão e análise de erros

c

Métricas utilizadas

Acurácia

- Mede a proporção total de acertos do modelo
- Responde: “de todas as críticas, quantas foram classificadas corretamente?”
- **Proporção geral de acertos.**

Precisão

- Mede, entre as críticas previstas como positivas, quantas eram realmente positivas
- Responde: “quando o modelo diz que é positivo, ele costuma acertar?”
- **Confiabilidade das previsões positivas**

Recall

- Mede, entre as críticas realmente positivas, quantas o modelo conseguiu encontrar
- Responde: “de todos os positivos reais, quantos foram identificados?”
- **Capacidade de encontrar os positivos reais**

F1-Score

- Combina precisão e recall em uma única métrica
- É útil quando queremos equilibrar os dois tipos de erro
- **Equilíbrio entre precisão e recall**

AUC-ROC

- Mede a capacidade do modelo de separar críticas positivas e negativas
- Quanto mais perto de 1, melhor a separação entre as classes
- **Capacidade de separar positivos e negativos.**

Resultados principais

Modelo	Acc	Prec	Recall	F1	AUC
Regressão Logística (baseline)	0,8906	0,8838	0,8994	0,8916	0,9582
Stacking	0,8677	0,8627	0,8746	0,8686	0,9415
LightGBM	0,8640	0,8553	0,8762	0,8656	0,9412
Random Forest	0,8212	0,7847	0,8854	0,8320	0,9048
XGBoost	0,8149	0,7825	0,8722	0,8249	0,9058
Embeddings + RL	0,8234	0,8233	0,8236	0,8234	0,9029


Comparação por F1-score




A solução mais simples foi a melhor: TF-IDF + Regressão Logística.

Perfil método por método


Regressão Logística




Stacking



LightGBM



Embeddings + RL



Teste com configurações mais pesadas

O que mudou?

- XGBoost: 100 para 200 estimadores; profundidade 4 para 6.
- LightGBM: 100 para 200 estimadores.
- Random Forest: 100 para 150 árvores; profundidade 10 para 12.
- Stacking: cv=2 para cv=5.

O que aconteceu?

- LightGBM, Stacking e XGBoost melhoraram.
- Mesmo assim, o baseline continuou em primeiro.
- Aumentar complexidade trouxe ganhos pontuais, mas não mudou a conclusão.

Interpretação dos resultados

Por que o baseline venceu?

- TF-IDF gera dados esparsos e de alta dimensão
- Modelos lineares funcionam muito bem nesse formato
- Palavras de sentimento forte já carregam muita informação

O que a modelagem mostrou?

- Comparar modelos complexos não garante melhora
- Embeddings gerais não superaram TF-IDF neste caso
- A melhor resposta veio da abordagem mais simples e bem ajustada

Limites do pipeline

Texto

- Ironias e frases ambíguas podem dificultar a interpretação do sentimento
- Críticas com opiniões positivas e negativas ao mesmo tempo tendem a ser mais difíceis de classificar

TF-IDF

- Representa frequência, não significado profundo
- Stopwords podem afetar negações

Embeddings

- Modelo leve e geral
- Reviews longas podem ser truncadas

Resposta ao ASK

Sim. O texto das críticas contém informação suficiente para prever o sentimento com bom desempenho.

Principal achado

- A Regressão Logística com TF-IDF obteve o melhor desempenho geral, com F1-score de 0,8916 e AUC-ROC de 0,9582

Conclusão final

- A originalidade não foi apenas usar modelos mais complexos, mas testar se eles realmente melhoravam a resposta. Neste caso, a solução mais simples foi a mais eficaz.